

Fakultet inženjerskih nauka  
Univerziteta u Kragujevcu

**Tema:**

*Predviđanje prognoze vremena na osnovu vremenskih serija pomoću  
LSTM modela*

**student:**  
*Nikola Mitrevski*  
*400/2021*

**predmetni profesor:**  
*Vesna Ranković*  
**predmetni asistent:**  
*Tijana Šušteršić*

Kragujevac 2021.

## Sadržaj:

1	Uvod.....	2
2	Uvoz potrebnih biblioteka .....	3
3	Uvoz skupa podataka.....	3
4	Definisanje naziva karakteristika i inicijalizacija parametara za obuku modela .....	4
5	Preprocesiranje podataka .....	5
6	Formiranje skupa podataka za obuku .....	5
7	Formiranje skupa podataka za validaciju.....	6
8	Definisanje modela .....	6
9	Obuka modela .....	7
10	Vizuelizacija gubitka modela .....	8
11	Vizualizacija predviđanja(validacije) modela .....	9
12	Literatura .....	12

## 1 Uvod

Vremenska serija je niz tačaka podataka indeksiranih vremenskim redosledom. Najčešće vremenska serija je niz snimljen u uzastopnim jednako raspoređenim tačkama u vremenu. Podaci o vremenskim serijama su jednostavno merenja ili događaji koji se prate tokom vremena.

U ovom radu biće implementiran primer za predviđanje prognoze vremena na osnovu vremenskih serija pomoću LSTM modela.

## 2 Uvoz potrebnih biblioteka

```
import pandas as pd
import matplotlib.pyplot as plt
import tensorflow as tf
from tensorflow import keras
```

## 3 Uvoz skupa podataka

U ovom radu je korišćen skup podataka o klimi u Jeni(Nemačka), koji je snimio institut Max Planck u periodu od 10.januara.2009 do 31.decembra.2016 i sastoji se od 14 karakteristika(tabela 1). Podaci iz ovog dataset-a su prikupljani na svakih 10 minuta.

Tabela 1 Jena Climate dataset karakteristike

Indeks	Karakteristike	Format	Objašnjenje
1	Date Time	01.01.2009 00:10:00	Referenca datum-vreme
2	p (mbar)	996.52	Jedinica za pritisak izvedena u pascal SI koja se koristi za kvantifikaciju unutrašnjeg pritiska.
3	T (degC)	-8.02	Temperatura u Celzijusima
4	Tpot (K)	265.4	Temperatura u Kelvinima
5	Tdew (degC)	-8.9	Temperatura u Celzijusima u odnosu na vlažnost.
6	rh (%)	93.3	Relativna vlažnost je mera koliko je vazduh zasićen vodenom parom. % određuje količinu vode sadržanu u objektima za prikupljanje.
7	VPmax (mbar)	3.33	Zasićenje pritiska pare
8	VPact (mbar)	3.11	Pritisak pare
9	VPdef (mbar)	0.22	Deficit pritiska pare
10	sh (g/kg)	1.94	Specifična vlažnost
11	H2OC (mmol/mol)	3.12	Koncentracija vodene pare
12	rho (g/m ** 3)	1307.75	Gustina vazduha
13	wv (m/s)	1.03	Brzina vetra
14	max. wv (m/s)	1.75	Maksimalna brzina vetra
15	wd (deg)	152.3	Pravac vetra u stepenima

```
df = pd.read_csv('../binder/jena_climate_2009_2016.csv')
```

## 4 Definisanje naziva karakteristika i inicijalizacija parametara za obuku modela

```
titles = [
    "Pressure",
    "Temperature",
    "Temperature in Kelvin",
    "Temperature (dew point)",
    "Relative Humidity",
    "Saturation vapor pressure",
    "Vapor pressure",
    "Vapor pressure deficit",
    "Specific humidity",
    "Water vapor concentration",
    "Airtight",
    "Wind speed",
    "Maximum wind speed",
    "Wind direction in degrees",
]

feature_keys = [
    "p (mbar)",
    "T (degC)",
    "Tpot (K)",
    "Tdew (degC)",
    "rh (%)",
    "VPmax (mbar)",
    "VPact (mbar)",
    "VPdef (mbar)",
    "sh (g/kg)",
    "H2OC (mmol/mol)",
    "rho (g/m**3)",
    "wv (m/s)",
    "max. wv (m/s)",
    "wd (deg)",
]

date_time_key = "Date Time"

split_fraction = 0.715
train_split = int(split_fraction * int(df.shape[0]))
step = 6

past = 720
future = 72
learning_rate = 0.001
batch_size = 256
epochs = 10
```

## 5 Preprocesiranje podataka

Pošto svaka karakteristika ima vrednosti iz različitog opsega, vrši se normalizacija podataka čime se vrednosti karakteristika ograničavaju na opseg od 0 do 1, da bi se dobili najtačniji rezultati.

```
def normalize(data, train_split):  
    data_mean = data[:train_split].mean(axis=0)  
    data_std = data[:train_split].std(axis=0)  
    return (data - data_mean) / data_std
```

Zbog suvišnosti nekih karakteristika, izdvojicemo korisne(Pressure, Temperature, Saturation vapor pressure, Vapor pressure deficit, Specific humidity, Airtight, Wind speed) u poseban skup podataka.

```
selected_features = [feature_keys[i] for i in [0, 1, 5, 7, 8, 10, 11]]  
features = df[selected_features]  
features.index = df[date_time_key]  
features.head()  
  
features = normalize(features.values, train_split)  
features = pd.DataFrame(features)  
features.head()  
  
train_data = features.loc[0 : train_split - 1]  
val_data = features.loc[train_split:]
```

## 6 Formiranje skupa podataka za obuku

```
start = past + future  
end = start + train_split  
  
x_train = train_data[[i for i in range(7)]].values  
y_train = features.iloc[start:end][[1]]  
  
sequence_length = int(past / step)  
  
dataset_train = keras.preprocessing.timeseries_dataset_from_array(  
    x_train,  
    y_train,  
    sequence_length=sequence_length,  
    sampling_rate=step,  
    batch_size=batch_size,  
)
```

Funkcija “timeseries\_dataset\_from\_array” uzima niz tačaka podataka prikupljenih u jednakim intervalima, zajedno sa parametrima vremenske serije(dužina niza, razmak između dva niza, itd.) da bi proizvela serije ulaza i željenih izlaza.

## 7 Formiranje skupa podataka za validaciju

```
x_end = len(val_data) - past - future

label_start = train_split + past + future

x_val = val_data.iloc[:x_end][[i for i in range(7)]].values
y_val = features.iloc[label_start:][[1]]

dataset_val = keras.preprocessing.timeseries_dataset_from_array(
    x_val,
    y_val,
    sequence_length=sequence_length,
    sampling_rate=step,
    batch_size=batch_size,
)
```

## 8 Definisanje modela

```
for batch in dataset_train.take(1):
    inputs, targets = batch

inputs = keras.layers.Input(shape=(inputs.shape[1], inputs.shape[2]))
lstm_out = keras.layers.LSTM(32)(inputs)
outputs = keras.layers.Dense(1)(lstm_out)

model = keras.Model(inputs=inputs, outputs=outputs)
model.compile(optimizer=keras.optimizers.Adam(learning_rate=learning_rate), loss="mse")
model.summary()
```

Model: "functional\_1"

Layer (type)	Output Shape	Param #
=====		
input_1 (InputLayer)	[(None, 120, 7)]	0
-----		
lstm (LSTM)	(None, 32)	5120
-----		
dense (Dense)	(None, 1)	33
=====		
Total params: 5,153		
Trainable params: 5,153		
Non-trainable params: 0		

Slika 1 Prikaz informacija strukture definisanog LSTM modela

## 9 Obuka modela

```
path_checkpoint = "model_checkpoint.h5"
es_callback = keras.callbacks.EarlyStopping(monitor="val_loss", min_delta=0, patience=5)

modelckpt_callback = keras.callbacks.ModelCheckpoint(
    monitor="val_loss",
    filepath=path_checkpoint,
    verbose=1,
    save_weights_only=True,
    save_best_only=True,
)

history = model.fit(
    dataset_train,
    epochs=epochs,
    validation_data=dataset_val,
    callbacks=[es_callback, modelckpt_callback],
)
```

Funkcija `ModelCheckpoint` se koristi za redovno čuvanje kontrolnih tačaka, a funkcija `EarlyStopping` za prekidanje obuke modela, kada se gubitak modela više ne poboljšava.

```
Epoch 1/10
1172/1172 [=====] - ETA: 0s - loss: 0.2059
Epoch 00001: val_loss improved from inf to 0.16357, saving model to model_checkpoint.h5
1172/1172 [=====] - 101s 86ms/step - loss: 0.2059 - val_loss: 0.1636
Epoch 2/10
1172/1172 [=====] - ETA: 0s - loss: 0.1271
Epoch 00002: val_loss improved from 0.16357 to 0.13362, saving model to model_checkpoint.h5
1172/1172 [=====] - 107s 92ms/step - loss: 0.1271 - val_loss: 0.1336
Epoch 3/10
1172/1172 [=====] - ETA: 0s - loss: 0.1089
Epoch 00003: val_loss did not improve from 0.13362
1172/1172 [=====] - 110s 94ms/step - loss: 0.1089 - val_loss: 0.1481
Epoch 6/10
271/1172 [=====>.....] - ETA: 1:12 - loss: 0.1117
```


Slika 2 Obuka LSTM modela (trajanje 6 epoha)



## 10 Vizuelizacija gubitka modela

```
def visualize_loss(history, title):
    loss = history.history["loss"]
    val_loss = history.history["val_loss"]
    epochs = range(len(loss))
    plt.figure()
    plt.plot(epochs, loss, "b", label="Training loss")
    plt.plot(epochs, val_loss, "r", label="Validation loss")
    plt.title(title)
    plt.xlabel("Epochs")
    plt.ylabel("Loss")
    plt.legend()
    plt.show()

visualize_loss(history, "Training and Validation Loss")
```



Slika 3 Vizuelizacija gubitka LSTM modela

Sa slike se vidi da posle prve epohe, gubitak prestaje da se smanjuje.


## 11 Vizualizacija predviđanja(validacije) modela

Predviđanje modela za 5 skupova vrednosti uzetih iz skupa za validaciju.


```
def show_plot(plot_data, delta, title):
    labels = ["History", "True Future", "Model Prediction"]
    marker = [".-", "rx", "go"]
    time_steps = list(range(-(plot_data[0].shape[0]), 0))
    if delta:
        future = delta
    else:
        future = 0

    plt.title(title)
    for i, val in enumerate(plot_data):
        if i:
            plt.plot(future, plot_data[i], marker[i], markersize=10, label=labels[i])
        else:
            plt.plot(time_steps, plot_data[i].flatten(), marker[i], label=labels[i])
    plt.legend()
    plt.xlim([time_steps[0], (future + 5) * 2])
    plt.xlabel("Time-Step")
    plt.show()
    return


for x, y in dataset_val.take(5):
    show_plot(
        [x[0][:, 1].numpy(), y[0].numpy(), model.predict(x)[0]],
        12,
        "Single Step Prediction",
    )
```




Slika 4 Grafički prikaz validacije LSTM modela za prvi skup podataka




Slika 5 Grafički prikaz validacije LSTM modela za drugi skup podataka



Slika 6 Grafički prikaz validacije LSTM modela za treći skup podataka



Slika 7 Grafički prikaz validacije LSTM modela za četvrti skup podataka



Slika 8 Grafički prikaz validacije LSTM modela za peti skup podataka

## 12 Literatura

[1] Keras -> Timeseries forecasting for weather prediction, link:

[https://keras.io/examples/timeseries/timeseries\\_weather\\_forecasting/?fbclid=IwAR1iQq-3pVDGqbt8rBQBN5d\\_qGRFfjJjDzgcxiKUTSRQ8TdgwBmCYOGwIVw](https://keras.io/examples/timeseries/timeseries_weather_forecasting/?fbclid=IwAR1iQq-3pVDGqbt8rBQBN5d_qGRFfjJjDzgcxiKUTSRQ8TdgwBmCYOGwIVw),

06.12.2021(10:12).